

(1) 根据《统计学习方法》中表5.1所给的训练集数据，利用信息增益比算法（C4.5算法）生成决策树。

第一次：

$$H(D) = -\frac{3}{5} \log \frac{3}{5} - \frac{2}{5} \log \frac{2}{5} = 0.971$$

$$g(D, A) = H(D) - H(D|A)$$

1° 年龄：

$$H(D|A_1) = \frac{1}{3} \times (-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5}) + \frac{1}{3} \times (-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5})$$

$$+ \frac{1}{3} \times (-\frac{4}{5} \log \frac{4}{5} - \frac{1}{5} \log \frac{1}{5}) = 0.888$$

$$H_{A_1}(D) = -\frac{1}{3} \log \frac{1}{3} - \frac{1}{3} \log \frac{1}{3} - \frac{1}{3} \log \frac{1}{3} = 1.585$$

$$g_R(D, A) = \frac{g(D, A)}{H_{A_1}(D)} = 0.052$$

2° 有工作：

$$H(D|A_2) = \frac{2}{3} \times (-\frac{2}{5} \log \frac{2}{5} - \frac{3}{5} \log \frac{3}{5}) + \frac{1}{3} \times 0$$
$$= 0.647$$

$$H_{A_2}(D) = -\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3} = 0.918$$

$$g_R(D, A) = \frac{g(D, A)}{H_{A_2}(D)} = 0.354$$

3° 有自己的房子

$$H(D|A_3) = \frac{2}{5} \times (-\frac{1}{3} \log \frac{1}{3} - \frac{2}{3} \log \frac{2}{3}) + \frac{2}{5} \times 0$$
$$= 0.551$$

$$H_{A_3}(D) = -\frac{2}{5} \log \frac{2}{5} - \frac{2}{5} \log \frac{2}{5} = 0.971$$

$$g_R(D, A_3) = \frac{g(D, A_3)}{H_{A_3}(D)} = 0.433$$

4° 信贷情况

$$H(D|A_4) = \frac{5}{15} \times (-\frac{4}{5} \log \frac{4}{5} - \frac{1}{5} \log \frac{1}{5}) + \frac{6}{15} \times (-\frac{2}{3} \log \frac{2}{3} - \frac{1}{3} \log \frac{1}{3})$$
$$+ \frac{4}{15} \times 0$$


$$= 0.608$$

$$H_{A_4}(D) = -\frac{5}{15} \log \frac{5}{15} - \frac{4}{15} \log \frac{4}{15} - \frac{6}{15} \log \frac{6}{15}$$

$$= 1.566$$

$$g_R(D, A_4) = \frac{g(D, A_4)}{H_{A_4}(D)} = 0.232$$

按有自己房子分两类



第二次:

$$H(D) = -\frac{1}{3}\log\frac{1}{3} - \frac{2}{3}\log\frac{2}{3} = 0.918$$

1° 年龄

$$H(D|A_1) = \frac{4}{9} \times (-\frac{1}{4}\log\frac{1}{4} - \frac{3}{4}\log\frac{3}{4}) + \frac{2}{9} \times 0 + \frac{3}{9} \times (-\frac{1}{3}\log\frac{1}{3} - \frac{2}{3}\log\frac{2}{3})$$

$$= 0.667$$

$$H_{A_1}(D) = -\frac{4}{9}\log\frac{4}{9} - \frac{2}{9}\log\frac{2}{9} - \frac{3}{9}\log\frac{3}{9} = 1.530$$

$$g_R(D|A_1) = \frac{g(D|A_1)}{H_{A_1}(D)} = 0.164$$


2° 有工作

$$H(D|A_2) = \frac{1}{3} \times 0 + \frac{2}{3} \times 0$$

$$H_{A_2}(D) = 0.918$$

$$g_R(D, A_2) = \frac{g(D, A_2)}{H_{A_2}(D)} = 1 \quad (\text{显然增益比不会比1大})$$

② 可以再按有工作分两类



至此全部分完, 结束

(2) 已知表 1 所示的训练数据，试用平方损失准则生成一个二叉回归树。（提示：写出计算步骤）

x_i	1	2	3	4	5	6	7	8	9	10
y_i	4.50	4.75	4.91	5.34	5.80	7.05	7.90	8.23	8.70	9.00

表 1: 训练数据表

第一次划分:

通过观察, 划分点出现在 $S=4, 5, 6$ 比较合理

需要求 $\min_s \sum_{x \leq s} (y_i - C_1)^2 + \sum_{x > s} (y_i - C_2)^2$ 记为 $R(s)$

1° $S=4$. $C_1 = \overline{y[1:4]}$ $C_2 = \overline{y[5:10]}$

$$R(4) = 0.3737 + 7.005 = 7.3787$$


2° $S=5$ $C_1 = \overline{y[1:5]}$ $C_2 = \overline{y[6:10]}$

$$R(5) = 1.0582 + 2.3005 = 3.3587$$

3° $S=6$ $C_1 = \overline{y[1:6]}$ $C_2 = \overline{y[7:10]}$

$$R(6) = 4.3582 + 0.7157 = 5.0739$$

在 $S=5$ 处划分



第二次划分 ($x = 1, 2, 3, 4, 5$)

1° $S=1$ $C_1 = y_1$, $C_2 = \overline{y[2:5]}$

$$R(1) = 0 + 0.6662 = 0.6662$$

2° $S=2$ $C_1 = \overline{y[1:2]}$ $C_2 = \overline{y[3:5]}$

$$R(2) = 0.0313 + 0.3962 = 0.4273$$

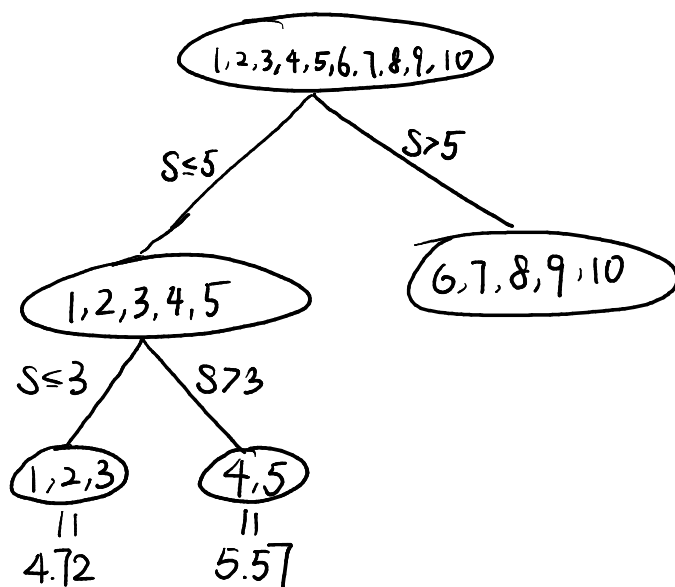
3° $S=3$ $C_1 = \overline{y[1:3]}$ $C_2 = \overline{y[4:5]}$

$$R(3) = 0.0854 + 0.1058 = 0.1912$$

4° $S=4$ $C_1 = \overline{y[1:4]}$ $C_2 = y_5$

$$R(4) = 0.3737 + 0 = 0.3737$$

在 $S=3$ 处划分, $C_1 = 4.72$, $C_2 = 5.57$



第¹次划分 ($x=6,7,8,9,10$)

$$1^\circ S=6 \quad C_1=y_6, C_2=y_{[7:10]}$$

$$R(6) = 0 + 0.7157 = 0.7157$$

$$2^\circ S=7 \quad C_1=y_{[6:7]}, C_2=y_{[8:10]}$$

$$R(7) = 0.3613 + 0.3013 = 0.6626$$

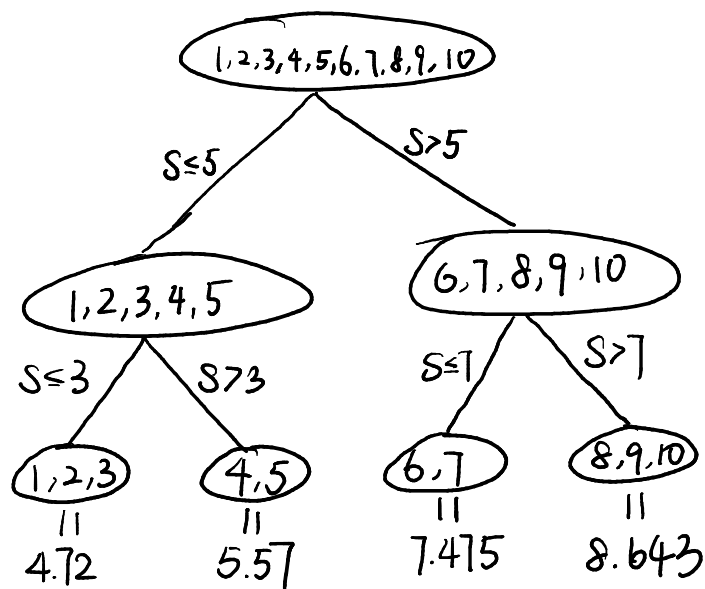
$$3^\circ S=8 \quad C_1=y_{[6:8]}, C_2=y_{[9:10]}$$

$$R(8) = 0.7413 + 0.0450 = 0.7863$$

$$4^\circ S=9 \quad C_1=y_{[6:9]}, C_2=y_{10}$$

$$R(9) = 1.4518 + 0 = 1.4518$$

在 $S=7$ 处划分, $C_1=7.475, C_2=8.643$



(3) 在CART剪枝过程中, 假设第 k 步, 对每个内部节点 t 计算 $C(T_t)$ 、 $|T_t|$ 以及

$$g_k(t) = \frac{C(t) - C(T_t)}{|T_t| - 1}$$

记第 k 步所有内部节点的集合为 \mathcal{M}_k , 记 $\alpha_k = g_k(a) = \min_{t \in \mathcal{M}_k} g_k(t)$, 即节点 a 是使函数 $g_k(t)$ 取值最小的内部节点 (假设此内部节点唯一), 则将 a 剪枝。记剪枝后内部节点的集合是 \mathcal{M}_{k+1} , 定义 $\alpha_{k+1} = g_{k+1}(b) = \min_{t \in \mathcal{M}_{k+1}} g_{k+1}(t)$ 。请证明 $\alpha_{k+1} > \alpha_k$ 。

证: $\because g_k(a) = \min_{t \in \mathcal{M}_k} g_k(t) = \alpha_k$

$C_k(T_a)$ 表示第 k 轮损失, $|T_a|_k$ 表示第 k 轮节点数

显然 $\forall t \in \mathcal{M}_{k+1}$, 若 t 的子节点在 k 轮未被剪枝, 结构完全一样

$$C_{k+1}(T_t) = C_k(T_t), |T_t|_{k+1} = |T_t|_k$$

若 t 的子节点被剪枝了 $|T_t|_{k+1} = |T_t|_k - |T_a|_k + 1$ (有 $|T_a|_k$ 节点被1个节点代替)

$$C_{k+1}(T_t) = C_k(T_t) - C_k(T_a) + C_k(a) \quad (T_t \text{ 的损失中 } T_a \text{ 子树的损失被 } a \text{ 单节点代替})$$

$$C_k(a) - C_k(T_a) = \alpha_k(|T_a|_k - 1)$$

$$\forall t \in \mathcal{M}_k \setminus \{a\}, C_k(t) - C_k(T_t) > \alpha_k(|T_t|_k - 1)$$

$\forall s \in \mathcal{M}_{k+1}$, 则显然 $s \neq a$,

若 a 不是 s 曾经子节点

$$\text{则 } C_{k+1}(s) - C_{k+1}(T_s) = C_k(s) - C_k(T_s) > \alpha_k(|T_s|_k - 1) = \alpha_k(|T_s|_{k+1} - 1)$$

若 a 曾经是 s 的子节点

$$\text{则 } C_{k+1}(s) - C_{k+1}(T_s) = C_k(s) - C_{k+1}(T_s)$$

$$\begin{aligned} C_{k+1}(T_s) &= C_k(T_s \setminus T_a) + C_k(a) = C_k(T_s) - C_k(T_a) + C_k(a) \\ &= C_k(T_s) - \alpha_k(|T_a|_k - 1) \end{aligned}$$

$$\begin{aligned} C_{k+1}(s) - C_{k+1}(T_s) &= C_k(s) - C_k(T_s) + \alpha_k(|T_a|_k - 1) \\ &> \alpha_k(|T_s|_k - 1 - |T_a|_k + 1) = \alpha_k(|T_s|_{k+1} - 1) \end{aligned}$$

$$\therefore \forall s \in \mathcal{M}_{k+1}, g(s) = \frac{C_{k+1}(s) - C_{k+1}(T_s)}{|T_s|_{k+1} - 1} > \alpha_k$$

$$\text{则 } \alpha_{k+1} = \min_{s \in \mathcal{M}_{k+1}} g(s) > \alpha_k$$