

# Naive Bayes Classifier (朴素贝叶斯方法)

## 1. 朴素贝叶斯法的学习及分类

### (1) 模型假设

输入:  $p$  维特征向量 (Covariate)  $x \in \mathbb{R}^p$ ;

输出: 类别标记 (class label)  $y \in \{c_1, \dots, c_K\}$ 。当  $K = 2$  时, 对应二分类问题。

训练数据集:  $T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}$ ; 假设  $(x_i, y_i)$  由联合概率分布  $P(X, Y)$  独立同分布产生。

目标: 朴素贝叶斯法通过训练数据学习联合概率分布  $P(X, Y)$ , 进而利用贝叶斯定理, 求出后验概率最大的输出  $y$ 。为得到  $P(X, Y)$ , 可以学习先验概率及条件概率分布。

- 先验概率分布:  $P(Y = c_k) \ (k = 1, \dots, K)$ 。
- 条件概率分布:

$$P(X = x | Y = c_k) = P(X^{(1)} = x^{(1)}, \dots, X^{(p)} = x^{(p)} | Y = c_k),$$

其中  $X^{(j)}$  和  $x^{(j)}$  分别代表  $X$  和  $x$  的第  $j$  个分量。

### (2) 后验概率最大化

给定输入  $x$ , 将后验概率最大的类作为  $x$  的类的输出。后验概率可由贝叶斯定理而得:

$$P(Y = c_k | X = x) = \frac{P(X = x | Y = c_k) P(Y = c_k)}{\sum_k P(X = x | Y = c_k) P(Y = c_k)} \quad (1.1)$$

### (3) 条件独立性假设

条件概率分布  $P(X = x | Y = c_k)$  的估计难度较大。假设  $x^{(j)}$  为离散型, 可能的取值有  $S_j$  个,  $Y$  的可能取值有  $K$  个, 那么待估的参数个数为  $K \prod_{j=1}^p S_j$ 。

因此，朴素贝叶斯法对条件概率做了**条件独立性假设**：

$$\begin{aligned} P(X = x|Y = c_k) &= P(X^{(1)} = x^{(1)}, \dots, X^{(p)} = x^{(p)}|Y = c_k) \\ &= \prod_{j=1}^p P(X^{(j)} = x^{(j)}|Y = c_k). \end{aligned}$$

这一假设使得朴素贝叶斯法变得简单，但会损失一定的分类准确性。

后验概率代入条件独立性假设的结果得：

$$P(Y = c_k|X = x) = \frac{P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)}|Y = c_k)}{\sum_k P(Y = c_k) \prod_j P(X^{(j)} = x^{(j)}|Y = c_k)}, \quad k = 1, 2, \dots, K \quad (1.2)$$

由于上式分母对于所有类别 $c_k$ 都相同，所以有：

$$y = \arg \max_{c_k} P(Y = c_k) \prod_{j=1}^p P(X^{(j)} = x^{(j)}|Y = c_k).$$

注：后验概率最大化等价于期望风险最小化（此时选择0-1损失函数）。

以下进一步说明：后验概率最大化等价于期望风险最小化（此时选择0-1损失函数）。

记0-1损失函数为 $L(Y, f(X)) = 1$  如果  $Y \neq f(X)$ ; 否则 $L(Y, f(X)) = 0$ . 此时期望函数为

$$R_{exp}(f) = E\{L(Y, f(X))\} = E_X\left\{\sum_k L(c_k, f(X))P(c_k|X)\right\}.$$

对期望风险极小化只需要对每个  $X = x$  逐个极小化，由此可得：

$$\begin{aligned}
 f(x) &= \arg \min_y \sum_k L(c_k, y) P(c_k | X = x) \\
 &= \arg \min_y \sum_k I(y \neq c_k) P(Y = c_k | X = x) \\
 &= \arg \min_y \{P(Y \neq y | X = x)\} \\
 &= \arg \max_y P(Y = y | X = x).
 \end{aligned}$$

因此，

$$f(x) = \arg \max_y P(Y = y | X = x).$$

## 2 参数估计

### 2.1 极大似然估计

先验概率的极大似然估计为：

$$P(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k)}{N} \quad (2.1)$$

设第  $j$  个特征可能的取值集合为  $a_{j1}, \dots, a_{js_j}$ ，则条件概率的极大似然估计为：

$$P(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_i I(x_i^{(j)} = a_{jl}, y_i = c_k)}{\sum_i I(y_i = c_k)} \quad (2.2)$$

### 2.2 学习与分类算法

输入：训练数据  $\{(x_1, y_1), \dots, (x_N, y_N)\}$

输出：实例  $x$  的分类。

(1) 计算先验概率(2.1)及条件概率 (2.2)

(2) 对于给定的实例  $x = (x^{(1)}, \dots, x^{(p)})^\top$  计算

$$P(Y = c_k) \prod_{j=1}^p P(X^{(j)} = x^{(j)} | Y = c_k), \quad k = 1, 2, \dots, K$$

(3) 确定x的分类:

注：对于连续变量X，可使用核方法（kernel methods）估计其概率密度函数，具体方法参见Elements Chapter 6.6.

## 2.3 贝叶斯估计

极大似然估计可能会出现估计的概率值为0的情形，会影响到后验概率的计算。此时往往采用贝叶斯估计。此时条件概率的估计为：

$$P_\lambda(X^{(j)} = a_{jl} | Y = c_k) = \frac{\sum_{i=1}^N I(x_i^{(j)} = a_{jl}, y_i = c_k) + \lambda}{\sum_{i=1}^N I(y_i = c_k) + S_j \lambda} \quad (2.3)$$

贝叶斯估计等价于随机变量在各个取值的频数上加 $\lambda$ 。一般取 $\lambda = 1$ 。

先验概率的贝叶斯估计为：

$$P_\lambda(Y = c_k) = \frac{\sum_{i=1}^N I(y_i = c_k) + \lambda}{N + K\lambda} \quad (2.4)$$