

1. 朴素贝叶斯分类

(1) 模型假设:

输入: p 维特征向量

输出: 类别标记 $y \in \{c_1, c_2, \dots, c_k\}$, 当 $k=2$ 时, 对应二分类问题

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$$

(x_i, y_i) 由 $P(X, Y)$ 独立同分布产生,

目标: 学习 $P(X, Y)$

• 先验概率分布 $P(Y=c_k) (k=1, 2, \dots, K)$

条件概率 $P(X=x | Y=c_k)$

(2) 后验概率最大化

$$P(Y=c_k | X=x) = \frac{P(X=x | Y=c_k) P(Y=c_k)}{\sum_k P(X=x | Y=c_k) P(Y=c_k)}$$

(3) 条件独立性假设

$P(X=x | Y=c_k)$ 设 $x^{(j)}$ 是离散值, 可能取值有 s_j 个, Y 的可能取值有 K 个

$$\begin{aligned} P(X=x | Y=c_k) &= P(x^{(1)}=x^{(1)}, x^{(2)}=x^{(2)}, \dots, x^{(p)}=x^{(p)} | Y=c_k) \\ &= \prod_{j=1}^p P(x^{(j)}=x^{(j)} | Y=c_k) \end{aligned}$$

这一假设使朴素贝叶斯变得简单, 但也会损失分类准确性

$$P(Y=c_k | X=x) = \frac{P(Y=c_k) \prod_{j=1}^p P(x^{(j)}=x^{(j)} | Y=c_k)}{\sum_{k=1}^K P(Y=c_k) \prod_{j=1}^p P(x^{(j)}=x^{(j)} | Y=c_k)}$$

由于分母都相同,

$$y = \arg \max_y P(Y=c_k) \prod_{j=1}^p P(x^{(j)}=x^{(j)} | Y=c_k)$$

注:后验概率最大化等价于期望风险最小化

$$(选择0-1损失) \quad L(Y, f(x)) = \begin{cases} 1 & Y \neq f(x) \\ 0 & Y = f(x) \end{cases}$$

$$\begin{aligned} R_{emp}(f) &= E\{L(Y, f(x))\} = E_x\{E_{Y|X}(L(Y, f(x))|X)\} \\ &= E_x\left\{\sum_k L(c_k, f(x)) P(Y=c_k|X)\right\} \end{aligned}$$

只需对每个 $X=x$ 每个极小化:

$$\begin{aligned} f(x) &= \underset{y}{\operatorname{argmin}} \sum_k L(c_k, y) P(c_k|X=x) \\ &= \underset{y}{\operatorname{argmin}} \sum_k I(c_k \neq y) P(c_k|X=x) \\ &= \underset{y}{\operatorname{argmin}} P(Y \neq y | X=x) = \underset{y}{\operatorname{argmax}} P(Y=y | X=x) \end{aligned}$$

2. 参数估计

2.1 极大似然估计

$$P(Y=c_k) = \frac{\sum_{i=1}^N I(y_i=c_k)}{N}$$

每个特征可能的取值集合 $\{a_{j1}, a_{j2}, \dots, a_{js_j}\}$

$$P(x^{(j)}=a_{jl} | Y=c_k) = \frac{\sum_i I(x_i^{(j)}=a_{jl}, y_i=c_k)}{\sum_i I(y_i=c_k)}$$

2.2 贝叶斯估计

$$P_\lambda(x^{(j)}=a_{jl} | Y=c_k) = \frac{\sum_i I(x_i^{(j)}=a_{jl}, y_i=c_k) + \lambda}{\sum_i I(y_i=c_k) + s_j \cdot \lambda}$$

$$P_\lambda(Y=c_k) = \frac{\sum_i I(y_i=c_k) + \lambda}{N + K\lambda}$$