
概率潜在语义分析

). 基本想法

一个文本(document)集合包含多个话题,一个话题由若干单词组成,选题无法直接观测需要数据估计。

目标:发现隐变量表示的话题,即潜在语义



语义相近的单词,语义相近的文本会被聚向相同的'软的类别'中

活题

2. 生成模型

数据

- (1)单词集合 W={W, W2, ..., Wm}
- (2) 文本集合 D= {d₁, d₂,..., d_N}
- (3) 活题集合 Z={Z,Z,...,Zx}

观测数据(word-doc)矩阵

	$\sqrt{(mq)}$	

- $\textcircled{d} \longrightarrow \textcircled{g} \longrightarrow \textcircled{w}$

 - ② P(wld), 治题 z
 - ③ P(WIZ) 单词W

概率表示


单词文本矩阵丁的生成概率

$$P(T) = \prod_{(w,d)} P(w,d)^{\Delta(w,d)}$$

3.模型参数

- (1)如果认为未知参数是P(w,d) MXN
- (2)参数个数 → 31 \ 16题 (M×K+K×N)

其中K<<M,N,大大减少3待估参数



4. 概率潜在语义模型求解

对数似然函数

$$L(\theta) = \sum_{i=1}^{M} \sum_{j=1}^{N} \Lambda(Wi,dj) \log P(Wi,dj)$$

$$= \sum_{i=1}^{M} \sum_{j=1}^{N} \Lambda(Wi,di) \log \{P(dj) \geq P(Wi|Zk) P(Zk|dj)\}$$

Yijk=1,代表dj产生3话题及, Zk产生3Wi P(Wilzk)P(Zkldj)

· E步: (计算Q函数)

$$Q(\theta, \theta^{(i)}) = \sum_{z} log P(Y, z|\theta) \cdot P(z|Y, \theta^{(i)})$$

完全样本似然函数

$$P(w,d,r|\theta) = \prod_{i=1}^{k} P(w_i,d_j,r_{ij1},r_{ij2},...,r_{ijk})$$

$$= \prod_{i=1}^{k} \prod_{j=1}^{k} \left[\prod_{k=1}^{k} \left\{ P(w_i|z_k) P(z_k|d_j) \right\}^{n_{jk}} P(d_j) \right]^{\Delta(w_i,d_j)}$$

$$\log P(w,d,z|\theta) = \sum_{i=1}^{N} \sum_{j=1}^{M} [\Lambda(w_i,d_j)] \log P(d_j) + \sum_{k=1}^{M} r_{ijk} \log P(w_i|z_k) \cdot P(z_k|d_j)]$$

$$Y_{ijk} = E[Y_{ijk} | W,d, 0]$$

$$= P(Z_{k} | W,d, 0) = \frac{P(Z_{k}, w_{i}|d_{j})}{P(w_{i}|d_{j})}$$

$$= \frac{P(w_{i}|z_{k})P(Z_{k}|d_{j})}{Z_{k}P(w_{i}|z_{k})P(Z_{k}|d_{j})} P(W_{i}|Z_{k})P(Z_{k}|d_{j}) 用上一步进代代入$$

M步:

$$Q(\theta, \theta^{(i)}) = \sum_{k=1}^{K} \sum_{j=1}^{M} \sum_{j=1}^{N} r_{ijk} \Delta(w_i, d_j) \log \{P(w_i | z_k) P(z_k | d_j)\}$$

約束:
$$\stackrel{M}{\underset{i=1}{\overset{M}{=}}} P(Wi|Z_K) = 1$$
, for $k=1,2,...,K$ $\frac{\overset{K}{\underset{k=1}{\overset{M}{=}}}}{P(Z_k|d_j)} = 1$, for $j=1,2,...,M$

定义Lagrange函数.

$$P(\text{WilZk}) = \frac{\sum_{j=1}^{N} \Delta(\text{Wi,dj}) \text{ fijk}}{\sum_{i=1}^{N} \sum_{j=1}^{N} \Delta(\text{Wi,dj}) \text{ fijk}} P(\text{Zkldj}) = \frac{\sum_{j=1}^{M} \Delta(\text{Wi,dj}) \text{ fijk}}{\sum_{k=1}^{N} \sum_{j=1}^{N} \Delta(\text{Wi,dj}) \text{ fijk}}$$